


# Regresión lineal

El modelo base para relacionar una respuesta con variables explicativas mediante una estructura afín

## En estas 3 slides

1. Formulación del modelo.
2. Estimación por mínimos cuadrados ordinarios.
3. Fortalezas, límites y lectura geométrica.

**Idea central:** es el punto de partida natural cuando queremos interpretación, rapidez y una teoría estadística clara.



# 1. Modelo y estimación OLS

- ▶ La regresión lineal postula

$$\mathbf{y} = \mathbf{X}\beta + \varepsilon, \quad y_i = \beta_0 + x_i^T \beta + \varepsilon_i.$$

- ▶ “Lineal” significa **lineal en los parámetros**. Por eso puede incluir transformaciones de variables sin dejar de ser un modelo lineal.
- ▶ El estimador de mínimos cuadrados ordinarios busca

$$\hat{\beta}_{\text{OLS}} \in \arg \min_{\beta \in \mathbb{R}^p} \|\mathbf{y} - \mathbf{X}\beta\|_2^2.$$

- ▶ Si  $\mathbf{X}^T \mathbf{X}$  es invertible,

$$\hat{\beta}_{\text{OLS}} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}.$$

## Lectura geométrica

La predicción

$$\hat{\mathbf{y}} = \mathbf{X}\hat{\beta}$$

es la proyección ortogonal de  $\mathbf{y}$  sobre el subespacio columna de  $\mathbf{X}$ .

## Qué optimiza

$$\text{RSS}(\beta) = \sum_{i=1}^n (y_i - x_i^T \beta)^2.$$

OLS elige la recta, plano o hiperplano que mejor aproxima a los datos en sentido cuadrático.

## 2. ¿Cuándo conviene y qué limita?

### Fortalezas

- ▶ Coeficientes interpretables.
- ▶ Entrenamiento muy rápido.
- ▶ Buen baseline para datos tabulares.
- ▶ Base natural para inferencia estadística.

### Lectura de coeficientes

$\beta_j$  mide el cambio esperado en la respuesta ante una variación unitaria en  $x_j$ , manteniendo fijas las demás covariables.

### Límites

- ▶ Sensible a outliers.
- ▶ Puede subajustar relaciones muy no lineales.
- ▶ Exige más ingeniería de variables.
- ▶ Sufre cuando hay fuerte multicolinealidad.

### Idea para recordar

La regresión lineal no es sólo un modelo simple: es también la referencia conceptual desde la cual se entienden muchas extensiones lineales y regularizadas.


# Ridge regression

La versión regularizada de OLS cuando la estimación lineal se vuelve inestable

## En esta sección

1. Por qué OLS puede fallar con multicolinealidad.
2. Penalización  $\ell_2$  y solución cerrada.
3. Interpretación geométrica del encogimiento.
4. Elección de  $\lambda$  y uso práctico.

**Idea central:** ridge introduce sesgo de manera controlada para reducir varianza y ganar




### 3. Definición y motivación

- ▶ Si los predictores están muy correlacionados, la matriz  $\mathbf{X}^T \mathbf{X}$  puede volverse mal condicionada.
- ▶ Entonces los coeficientes OLS adquieren gran varianza y se vuelven sensibles a perturbaciones pequeñas de la muestra.
- ▶ Ridge reemplaza OLS por el problema penalizado

$$\hat{\beta}_{\lambda} \in \arg \min_{\beta} \left\{ \|\mathbf{y} - \mathbf{X}\beta\|_2^2 + \lambda \|\beta\|_2^2 \right\}, \quad \lambda \geq 0.$$

- ▶ Si la intersección se trata aparte,

$$\hat{\beta}_{\lambda} = (\mathbf{X}^T \mathbf{X} + \lambda I)^{-1} \mathbf{X}^T \mathbf{y}.$$




Fuente visual: Ridge, scikit-learn.

## 4. Interpretación geométrica y estadística

- ▶ Ridge puede verse también como una versión restringida de OLS:

$$\min_{\beta} \|\mathbf{y} - \mathbf{X}\beta\|_2^2 \quad \text{sujeto a} \quad \|\beta\|_2^2 \leq c.$$

- ▶ La bola euclídea impide que los coeficientes crezcan demasiado.
- ▶ Desde el punto de vista estadístico, el método acepta un poco más de sesgo para reducir notablemente la varianza del estimador.



Fuente visual: Esquema geométrico del problema restringido de ridge.

### Mensaje conceptual

Ridge no cambia la familia de modelos lineales; cambia la forma en que estimamos sus coeficientes cuando OLS es demasiado inestable.

## 5. Efecto de la penalización $\ell_2$


- ▶ Al crecer  $\lambda$ , los coeficientes se **encogen** hacia cero de manera continua.
- ▶ Ridge no hace selección exacta: en general no anula coeficientes, sólo los reduce.
- ▶ El beneficio es el clásico **trade-off sesgo-varianza**: algo más de sesgo, mucha menos varianza.
- ▶ También mejora el condicionamiento numérico del problema.

### Cuándo conviene

Cuando hay multicolinealidad o cuando queremos un modelo lineal más estable sin eliminar variables.

### Buena práctica

Estandarizar variables y elegir  $\lambda$  mediante validación cruzada.




Fuente visual: Coeficientes con ridge, scikit-learn.

## 6. ¿Cómo se elige $\lambda$ y cuándo usar ridge?

- ▶  $\lambda = 0$  recupera OLS; valores grandes fuerzan un encogimiento más agresivo.
- ▶ En la práctica,  $\lambda$  se selecciona por validación cruzada, equilibrando error de predicción y estabilidad.
- ▶ Ridge suele funcionar bien cuando hay muchos predictores con información repartida, en lugar de unas pocas variables claramente dominantes.

### Escenarios típicos

Multicolinealidad, alta dimensión moderada y necesidad de un modelo lineal robusto para predicción.



Fuente visual: Trayectorias de coeficientes según la regularización, scikit-learn.




# Random Forest

De árboles inestables a un ensemble robusto: bootstrap, aleatorización y agregación


## Ruta de la sección

1. Árboles de decisión e inestabilidad.
2. Qué es bootstrap y por qué aparece en random forest.
3. Bagging, submuestreo de variables y voto.
4. OOB, importancia de variables e hiperparámetros.



**Idea clave:** random forest mejora a un árbol individual porque promedia muchos árboles fuertes para

## 7. Árboles de decisión: la pieza básica del bosque



Fuente visual: Árbol de decisión pedagógico, búsqueda web.



Fuente visual: Árbol aprendido sobre Iris, scikit-learn.

### Lectura de la slide


Cada árbol construye reglas del tipo  $x_j \leq t$  de manera recursiva. Es un modelo muy flexible y muy interpretable: la predicción se obtiene recorriendo un camino desde la raíz hasta una hoja.

## 8. El problema: un árbol solo suele tener alta varianza

- ▶ Un árbol profundo suele tener **bajo sesgo** pero **alta varianza**.
- ▶ Pequeñas perturbaciones en los datos pueden cambiar mucho los cortes aprendidos.
- ▶ Por eso, dos muestras parecidas pueden inducir árboles bastante distintos y producir predicciones inestables.
- ▶ Random forest nace precisamente para atacar esta inestabilidad por medio de la agregación.

### Moral

Un árbol aislado es un predictor *fuerte pero sensible*; el bosque busca convertir muchos predictores sensibles en un predictor final mucho más estable.




Misma tarea, árbol distinto tras una perturbación pequeña en la muestra.

## 9. ¿Qué significa hacer bootstrap?

- ▶ Partimos del dataset original

$$\mathcal{D} = \{(x_i, y_i) : i = 1, \dots, n\}.$$

- ▶ Una **muestra bootstrap** se construye tomando  $n$  observaciones con reemplazo desde  $\mathcal{D}$ .
- ▶ “Con reemplazo” significa que una observación puede aparecer varias veces y otra puede no aparecer.
- ▶ Así obtenemos un nuevo conjunto  $\mathcal{D}^*$  del mismo tamaño, pero con composición distinta.



Fuente visual: Esquema online de bootstrap sampling recuperado vía búsqueda web.

### Punto conceptual


Bootstrap no crea información nueva: crea **versiones remuestreadas** del dataset para inducir variabilidad controlada entre modelos.

## 10. ¿Por qué bootstrap es útil en random forest?


- ▶ Si entrenáramos todos los árboles sobre exactamente el mismo dataset, tenderían a parecerse demasiado.
- ▶ El remuestreo bootstrap hace que cada árbol vea una versión diferente del conjunto de entrenamiento.
- ▶ Eso introduce diversidad entre árboles, que luego puede aprovecharse al promediar.
- ▶ En promedio, cada muestra bootstrap contiene alrededor del **63.2 %** de observaciones únicas y deja fuera aproximadamente el **36.8 %** restante para ese árbol.

### Consecuencia importante

Esas observaciones no utilizadas por un árbol se llaman *out-of-bag* para ese árbol y luego permiten estimar error de generalización sin un conjunto de validación extra.



# 11. Del bootstrap al bagging



Fuente visual: Diagrama online de bootstrap y bagging.

- ▶ **Bagging** significa: entrenar muchos predictores sobre muestras bootstrap y luego agregarlos.
- ▶ En random forest, esos predictores base son árboles de decisión.
- ▶ Si cada árbol se equivoca de manera algo distinta, el promedio o el voto mayoritario reducen la varianza del predictor final.

## Idea central


Bagging explota una propiedad clásica: *promediar predictores inestables puede producir un predictor estable.*

## 12. ¿Cómo se entrena un random forest completo?

1. Tomar una muestra bootstrap del dataset.
2. Entrenar un árbol profundo sobre esa muestra.
3. En cada nodo, evaluar sólo un subconjunto aleatorio de variables.
4. Repetir este proceso  $B$  veces.
5. Agregar las predicciones por voto mayoritario o promedio.

### Por qué funciona


La combinación de **bootstrap** y **submuestreo de variables** reduce la correlación entre árboles; la etapa de agregación aprovecha esa diversidad para estabilizar la predicción.



Fuente visual: Esquema online de random forest.

## 13. Aleatoriedad en variables: la diferencia con bagging puro

- ▶ Si todos los árboles compitieran siempre con todas las variables, muchos se parecerían demasiado.
- ▶ Esto ocurre especialmente cuando existe una variable muy dominante: casi todos los árboles la elegirían en la raíz.
- ▶ Random forest evita eso forzando que, en cada nodo, sólo se evalúe un subconjunto aleatorio de variables, denotado por  $m_{\text{try}}$ .



Fuente visual: Ejemplo online del efecto de `max_features` y número de árboles en random forest.

### Regla práctica

En clasificación suele usarse  $m_{\text{try}} \approx \sqrt{p}$ ; en regresión, valores mayores son frecuentes.




## 14. Voto y promedio: cómo decide el bosque


- ▶ En **clasificación**, cada árbol vota por una clase y el bosque devuelve la clase más frecuente.
- ▶ En **regresión**, cada árbol devuelve un número y el bosque responde con el promedio.
- ▶ La mejora no proviene de que cada árbol sea perfecto, sino de que el ensamble promedia errores parcialmente independientes.

### Lectura intuitiva

Random forest funciona como una comisión de expertos: ningún árbol es completamente confiable, pero el conjunto puede ser muy robusto.



## 15. Error OOB: validación interna del bosque




Fuente visual: Curva OOB, scikit-learn.

- ▶ Para cada observación, podemos reunir las predicciones de los árboles en los que esa observación quedó *out-of-bag*.
- ▶ Esa agregación produce una estimación interna del error de generalización.
- ▶ Es una de las ventajas prácticas de random forest: muchas veces evita reservar un conjunto de validación adicional.

### Interpretación

Cuando el error OOB se estabiliza al crecer el número de árboles, suele ser una señal de que el bosque ya alcanzó su régimen estable.

## 16. Importancia de variables: qué aprendió el bosque



Fuente visual: Importancia de variables, scikit-learn.

- ▶ Random forest permite estimar qué variables resultan más influyentes para la predicción.
- ▶ Una vía clásica es medir la reducción acumulada de impureza inducida por cada variable a lo largo del bosque.
- ▶ Otra opción, más robusta, es la *permutation importance*, que evalúa cuánto empeora el desempeño al permutar una variable.

### Cuidado

Importancia no significa causalidad: una variable puede aparecer como muy importante por correlación predictiva, no por efecto causal.

## 17. Hiperparámetros clave y lectura práctica

| Parámetro               | Efecto principal                                                 |
|-------------------------|------------------------------------------------------------------|
| $n_{\text{estimators}}$ | Más árboles suelen bajar la varianza hasta estabilizar el error. |
| max_depth               | Controla la complejidad de cada árbol base.                      |
| max_features            | Regula la aleatorización en cada nodo.                           |
| min_samples_leaf        | Evita hojas demasiado pequeñas y reduce sobreajuste local.       |
| bootstrap               | Activa el remuestreo con reemplazo para bagging.                 |

### Conviene cuando...

Buscamos un baseline fuerte, hay no linealidades e interacciones, y priorizamos desempeño predictivo y robustez sobre una explicación global simple.

### Advertencia

Aunque es mucho más interpretable que otros ensambles complejos, la explicación global del bosque nunca es tan transparente como la de un árbol individual.


# 18. Resumen operativo de random forest

## Receta conceptual

árboles profundos + bootstrap  
+ submuestreo de variables + promedio/voto  
⇒ predictor estable, flexible y competitivo.


## Idea final para recordar

- ▶ El bosque no elimina la complejidad de un árbol: la **distribuye** y luego la **promedia**.
- ▶ Su fortaleza central es la **reducción de varianza** sin perder demasiada capacidad no lineal.




Fuente visual: Random forest, búsqueda web.

# 19. Comparación entre regresión lineal, ridge y random forest




## Regresión lineal

- ▶ Modelo lineal simple e interpretable.
- ▶ Muy útil como baseline.
- ▶ Conviene cuando la estructura es aproximadamente aditiva y queremos leer coeficientes.



## Ridge

- ▶ Sigue siendo lineal, pero regularizado.
- ▶ Reduce varianza y estabiliza coeficientes.
- ▶ Conviene con multicolinealidad o muchos predictores correlacionados.



## Random forest

- ▶ Modelo no lineal basado en ensambles.
- ▶ Capta interacciones complejas con poco preprocesamiento.
- ▶ Conviene cuando priorizamos desempeño predictivo y robustez.

## Resumen rápido

Si la prioridad es **interpretar efectos**, empezamos por regresión lineal; si además hay **inestabilidad o multicolinealidad**, pasamos a ridge; si sospechamos **no linealidades e interacciones complejas**, random forest suele ser una opción más potente.

## 20. Ejemplo aplicado: ¿Qué modelo elegiríamos?

### Escenario

Queremos predecir el **precio de viviendas** a partir de superficie, antigüedad, barrio, cantidad de ambientes, cercanía a servicios y otras covariables.

### Lectura pedagógica

- ▶ Si queremos una explicación clara del efecto de cada variable, probamos **regresión lineal**.
- ▶ Si muchas variables están correlacionadas y OLS se vuelve inestable, preferimos **ridge**.
- ▶ Si creemos que hay umbrales, interacciones y relaciones no lineales, **random forest** puede capturar mejor esa complejidad.

